

ПРАВИТЕЛЬСТВО РОССИЙСКОЙ ФЕДЕРАЦИИ
НАЦИОНАЛЬНЫЙ ИССЛЕДОВАТЕЛЬСКИЙ УНИВЕРСИТЕТ
«ВЫСШАЯ ШКОЛА ЭКОНОМИКИ»

Факультет компьютерных наук
Департамент программной инженерии

СОГЛАСОВАНО

УТВЕРЖДАЮ

Профессор департамента программной инженерии ФКН НИУ ВШЭ

Академический руководитель образовательной программы «Программная инженерия»

« ____ » _____ 2026 г.

« ____ » _____ 2026 г.

ГЕНЕРАТОР ДАННЫХ ДЛЯ АНАЛИТИЧЕСКОГО
БЕНЧМАРКА СУБД ТРС-Н

Пояснительная записка

Лист УТВЕРЖДЕНИЯ

RU.17701729.11.03-01 81 01-1-ЛУ

Подп. и дата	
Инв. № дубл.	
Взам. инв. №	
Подп. и дата	
Инв. № подл	

Исполнитель: Студент БПИ225

« ____ » _____ 2026 г.

УТВЕРЖДЁН
RU.17701729.11.03-01 81 01-1-ЛУ

ГЕНЕРАТОР ДАННЫХ ДЛЯ АНАЛИТИЧЕСКОГО
БЕНЧМАРКА СУБД ТРС-Н

Пояснительная записка

RU.17701729.11.03-01 81 01-1

Листов 19

Инв. № подл	Подп. и дата	Взам. инв. №	Инв. № дубл.	Подп. и дата

Содержание

1	Введение	3
1.1	Наименование разработки	3
1.2	Документы, являющиеся основанием для разработки	3
1.3	Предпосылки разработки	3
2	Назначение и область применения	4
2.1	Назначение программы	4
2.2	Область применения программы	4
3	Технические характеристики	5
3.1	Постановка задачи, применяемые методы, допущения и ограничения	5
3.2	Описание алгоритма и функционирования программы	5
3.3	Организация входных и выходных данных	11
3.4	Состав технических и программных средств	12
4	Ожидаемые технико-экономические показатели	13
4.1	Сокращение трудоемкости подготовки данных	13
4.2	Снижение инфраструктурных издержек	13
4.3	Расширение вариантов интеграции	13
4.4	Ожидаемые оперативные показатели	16
5	Источники, использованные при разработке	17

Изм.	Лист	№ докум.	Подп.	Дата
RU.17701729.11.03-01 81 01-1				
Инв. № подл.	Подп. и дата	Взам. инв. №	Инв. № дубл.	Подп. и дата

1. Введение

1.1. Наименование разработки

1.1.1. Наименование разработки на русском языке

«Генератор данных для аналитического бенчмарка СУБД TPC-H».

1.1.2. Наименование разработки на английском языке

«Data Generator for the TPC-H Analytical DBMS Benchmark».

1.1.3. Условное обозначение темы разработки

Schengen.

Исходный код программы размещается в репозитории Schengen [10].

1.2. Документы, являющиеся основанием для разработки

Разработка ведется на основании следующих документов:

- 1) учебный план подготовки бакалавров по направлению 09.03.04 «Программная инженерия» федерального государственного автономного образовательного учреждения высшего образования Национальный исследовательский университет «Высшая школа экономики»;
- 2) утвержденная академическим руководителем образовательной программы тема выпускной квалификационной работы «Генератор данных для аналитического бенчмарка СУБД TPC-H»;
- 3) техническое задание RU.17701729.04.03-01 ТЗ 01-1, разработанное в рамках выполнения выпускной квалификационной работы.

1.3. Предпосылки разработки

Необходимость разработки определяется тем, что существующие генераторы данных TPC-H [1] либо ориентированы на вывод в строковые файлы `tbl/csv` [4], либо не учитывают требований современной инфраструктуры аналитического хранения и обработки данных, использующей колоночные форматы `Parquet` [5] и `ORC` [6], а также табличные слои `lakehouse`-платформ [7].

В практических сценариях разработки и исследования аналитических систем требуется средство, обеспечивающее детерминированную генерацию таблиц TPC-H [1], прямую запись в современные колоночные форматы `Parquet` [5], `ORC` [6], `Lance` [8] и `Vortex` [9], поддержку параллельного формирования партиций в духе систем параллельной обработки данных [2] и возможность работы как с локальной файловой системой, так и с `S3`-совместимыми хранилищами.

Изм.	Лист	№ докум.	Подп.	Дата
RU.17701729.11.03-01 81 01-1				
Инв. № подл.	Подп. и дата	Взам. инв. №	Инв. № дубл.	Подп. и дата

2. Назначение и область применения

2.1. Назначение программы

Назначением программы является формирование синтетических данных аналитического бенчмарка ТРС-Н [1] с заданным масштабом генерации и сохранением результатов в форматах, пригодных для непосредственного использования в современных аналитических системах и подсистемах хранения данных.

Программа предназначена для детерминированной генерации таблиц набора ТРС-Н, их представления в колоночной форме Apache Arrow [3] и записи результата в поддерживаемые форматы хранения без промежуточного этапа ручной конвертации. В отличие от традиционных генераторов, ограниченных выводом в `tbl/csv` [4], разрабатываемая программа обеспечивает прямое формирование данных в форматах Parquet [5], ORC [6], Lance [8] и Vortex [9] и допускает запись как на локальную файловую систему, так и в S3-совместимые объектные хранилища.

2.2. Область применения программы

Программа может применяться при разработке, испытаниях и исследовании аналитических СУБД и OLAP-движков [2], lakehouse-платформ, подсистем хранения данных и других программных средств, работающих с большими объемами колоночных данных.

Основными областями применения программы являются:

- 1) подготовка воспроизводимых наборов данных для функционального и нагрузочного тестирования аналитических систем;
- 2) исследование характеристик различных форматов хранения и стратегий записи данных;
- 3) проверка корректности работы систем чтения, сериализации и обработки колоночных данных;
- 4) проведение сравнительных экспериментов, связанных с локальным и удаленным размещением аналитических наборов данных.

Программа ориентирована на использование разработчиками, исследователями, инженерами по тестированию и иными специалистами, которым требуется быстрое, детерминированное и масштабируемое получение данных набора ТРС-Н в форме, непосредственно пригодной для дальнейшего анализа и эксплуатации.

Изм.	Лист	№ докум.	Подп.	Дата
RU.17701729.11.03-01 81 01-1				
Инв. № подл.	Подп. и дата	Взам. инв. №	Инв. № дубл.	Подп. и дата

3. Технические характеристики

3.1. Постановка задачи, применяемые методы, допущения и ограничения

Задача разработки заключается в создании программы, обеспечивающей генерацию таблиц аналитического бенчмарка ТРС-Н [1] в соответствии с правилами и распределениями эталонной спецификации с возможностью выбора масштаба генерации, состава формируемых таблиц, формата хранения результата и способа организации записи выходных данных.

При разработке применяются методы детерминированной генерации данных на основе фиксированных последовательностей случайных значений, используемых в классическом генераторе ТРС-Н [1], методы колоночного представления данных в оперативной памяти [3], а также методы разбиения таблиц на партиции с последующим параллельным формированием и сериализацией результата. Для обеспечения совместимости с современными аналитическими форматами в качестве внутреннего представления используются колоночные структуры данных Apache Arrow [3].

В качестве основных допущений и ограничений принимается, что программа работает с фиксированным составом таблиц набора ТРС-Н и использует заданные спецификацией схемы, распределения и правила вычисления зависимых атрибутов. Поддерживаемые форматы хранения и конкретные параметры сериализации определяются конфигурацией сборки программы и набором подключенных форматных библиотек Parquet [5], ORC [6], Lance [8] и Vortex [9]. Возможность записи в удаленные хранилища определяется доступностью соответствующей файловой подсистемы и корректностью указанного URI.

3.2. Описание алгоритма и функционирования программы

3.2.1. Общая идея алгоритма

Функционирование программы организовано как последовательность этапов выбора сценария генерации, формирования таблиц и записи результата.

На первом этапе программа обрабатывает параметры командной строки, определяющие масштаб генерации, состав таблиц, формат вывода и путь размещения результата. После этого выполняется регистрация метаданных таблиц и выбирается требуемый драйвер сериализации.

На втором этапе для каждой выбранной таблицы определяется объем данных и схема разбиения на логические партиции. Далее для каждой партиции запускается генератор, формирующий значения атрибутов по детерминированным правилам ТРС-Н.

На третьем этапе сгенерированные значения накапливаются и объединяются в батчи для увеличения пропускной способности. После этого батчи передаются слою сериализации, который сохраняет результат в требуемом формате хранения.

3.2.2. Генерация значений и использование текстового пула

Формирование значений атрибутов основано на детерминированных последовательностях случайных чисел с фиксированными начальными значениями. За счет этого при одинаковых параметрах запуска программа воспроизводит один и тот же набор данных независимо от числа партиций и конфигурации параллельного выполнения.

Для числовых атрибутов используются ограниченные генераторы целых значений. Они применяются, например, при получении размеров деталей, балансов клиентов и поставщиков, скидок, налогов, датовых смещений и других величин, для которых спецификацией ТРС-Н задан

Изм.	Лист	№ докум.	Подп.	Дата
RU.17701729.11.03-01 81 01-1				
Инв. № подл.	Подп. и дата	Взам. инв. №	Инв. № дубл.	Подп. и дата

конечный диапазон допустимых значений. Для больших диапазонов ключей используется расширенный вариант генерации, допускающий работу с 64-разрядными значениями.

Для строковых атрибутов применяются несколько способов формирования значения. Значения из фиксированных словарей, например сегменты рынка, приоритеты заказов, типы деталей, инструкции отгрузки и режимы доставки, выбираются из взвешенных распределений. Имена деталей формируются как последовательности токенов, а адреса строятся как алфавитно-цифровые строки переменной длины. Телефонные номера вычисляются из ключа страны и случайных локальных компонент.

Генерация текстовых атрибутов в ТРС-Н задается набором распределений из файла `dists.dss` [1]. Каждый блок содержит имя распределения и число элементов `COUNT`. Далее приводится список токенов с соответствующими весами; вес определяет относительную частоту выбора токена.

```
# <token> / <weight> # comment

BEGIN articles
COUNT|3
the|50
a|20
an|5
END articles
```

Листинг 1 - Общий вид распределения

Распределение `grammar` задает верхнеуровневую схему предложения. Символы N, V, P и T обозначают именную группу, глагольную группу, предложную группу и знак завершения предложения.

```
###
# grammar
# first level grammar. N=noun phrase, V=verb phrase,
# P=prepositional phrase, T=sentence termination
##
BEGIN grammar
COUNT|5
N V T|3
N V P T|3
N V N T|3
N P V N T|1
N P V P T|1
END grammar
```

Листинг 2 - Верхнеуровневая грамматика предложения

Далее нетерминальные символы раскрываются через распределения `np` и `vp`, которые определяют внутреннюю форму именной и глагольной групп.

```
###
# NP
BEGIN np
COUNT|4
N|10
J N|20
J, J N|10
D J N|50
END np
```

Изм.	Лист	№ докум.	Подп.	Дата
RU.17701729.11.03-01 81 01-1				
Инв. № подл.	Подп. и дата	Взам. инв. №	Инв. № дубл.	Подп. и дата

```

###
# VP
BEGIN vp
COUNT|4
V|30
X V|1
V D|40
X V D|1
END vp

```

Листинг 3 - Раскрытие именной и глагольной групп

Терминальные символы подставляются из словарей отдельных частей речи, например **nouns** и **verbs**.

```

BEGIN nouns
COUNT|45
packages|40
requests|40
accounts|40
deposits|40
foxes|20
ideas|20
END nouns

BEGIN verbs
COUNT|40
sleep|20
wake|20
are|20
cajole|20
haggle|20
END verbs

```

Листинг 4 - Словари терминальных токенов

Из получаемых предложений заранее формируется **TextPool** - общий текстовый буфер. При генерации конкретного комментария программа выбирает в нем смещение и длину фрагмента, после чего использует соответствующий срез как значение атрибута. Такой подход уменьшает накладные расходы при генерации длинных текстовых полей. Для некоторых таблиц, например **supplier**, поверх выбранного текста дополнительно может применяться модификация по правилу **BBV**¹, предусмотренному спецификацией ТРС-Н [1].

3.2.3. Формирование таблиц набора данных

Генерация каждой таблицы выполняется отдельным модулем. Для всех таблиц используются фиксированные схемы и согласованные правила формирования ключей и зависимых атрибутов.

¹Правило **BBV** применяется при формировании атрибута **s_comment** таблицы **supplier**: в текст комментария вставляется подстрока **Customer Complaints** или **Customer Recommends** [1].

Изм.	Лист	№ докум.	Подп.	Дата
RU.17701729.11.03-01 81 01-1				
Инв. № подл.	Подп. и дата	Взам. инв. №	Инв. № дубл.	Подп. и дата




Рис. 1 - Схема формирования текстовых атрибутов на основе пула текста

3.2.3.1. Таблица region

Атрибут	Ключ	Правило формирования
r_regionkey	РК	Последовательная нумерация строк, начиная с нуля.
r_name		Выбирается из фиксированного справочника регионов ТРС-Н.
r_comment		Выбирается из пула текста TextPool.

3.2.3.2. Таблица nation

Атрибут	Ключ	Правило формирования
n_nationkey	РК	Последовательная нумерация строк, начиная с нуля.
n_name		Выбирается из предопределенного справочника наций.
n_regionkey	FK	Вычисляется по таблице наций и весам распределения регионов, заданным спецификацией ТРС-Н.
n_comment		Выбирается из пула текста TextPool.

3.2.3.3. Таблица supplier

Атрибут	Ключ	Правило формирования
s_suppkey	РК	Номер строки с единичным смещением.
s_name		Формируется по шаблону Supplier#%09d.
s_address		Формируется как алфавитно-цифровая строка переменной длины.
s_nationkey	FK	Выбирается из допустимого диапазона ключей наций.
s_phone		Вычисляется из ключа страны и случайных локальных компонент.
s_acctbal		Генерируется как ограниченное числовое значение и переводится в денежный формат.
s_comment		Выбирается из пула текста; при выполнении условия может модифицироваться по правилу ВВВ.

Изм.	Лист	№ докум.	Подп.	Дата
RU.17701729.11.03-01 81 01-1				
Инв. № подл.	Подп. и дата	Взам. инв. №	Инв. № дубл.	Подп. и дата

3.2.3.4. Таблица part

Атрибут	Ключ	Правило формирования
p_partkey	РК	Последовательная нумерация строк с единичным смещением.
p_name		Формируется как последовательность токенов из словаря цветов.
p_mfgr		Строится по номеру производителя.
p_brand		Вычисляется по номеру производителя и дополнительному номеру бренда.
p_type		Выбирается из словаря типов деталей.
p_size		Генерируется из ограниченного числового диапазона.
p_container		Выбирается из словаря контейнеров.
p_retailprice		Детерминированно вычисляется по ключу детали.
p_comment		Выбирается из пула текста TextPool.

3.2.3.5. Таблица partsupp

Атрибут	Ключ	Правило формирования
ps_partkey	FK	Соответствует текущей детали.
ps_suppkey	FK	Вычисляется как детерминированное отображение пары «ключ детали, номер поставщика»; для каждой детали формируются четыре поставщика.
ps_availqty		Генерируется из ограниченного диапазона доступного количества.
ps_supplycost		Генерируется из ограниченного диапазона и переводится в денежный формат.
ps_comment		Выбирается из пула текста TextPool.

3.2.3.6. Таблица customer

Атрибут	Ключ	Правило формирования
c_custkey	РК	Последовательная нумерация строк с единичным смещением.
c_name		Формируется по шаблону Customer#%09d.
c_address		Формируется как алфавитно-цифровая строка переменной длины.
c_nationkey	FK	Выбирается из допустимого диапазона ключей наций.
c_phone		Вычисляется из ключа страны и случайных локальных компонент.
c_acctbal		Генерируется как ограниченное числовое значение и переводится в денежный формат.
c_mktsegment		Выбирается из словаря сегментов рынка.
c_comment		Выбирается из пула текста TextPool.

Изм.	Лист	№ докум.	Подп.	Дата
RU.17701729.11.03-01 81 01-1				
Инв. № подл.	Подп. и дата	Взам. инв. №	Инв. № дубл.	Подп. и дата

3.2.3.7. Таблица orders

Атрибут	Ключ	Правило формирования
o_orderkey	PK	Строится по разреженной схеме из порядкового номера заказа.
o_custkey	FK	Выбирается из диапазона клиентов с исключением недопустимых ключей.
o_orderstatus		Определяется по числу отгруженных позиций заказа.
o_totalprice		Вычисляется как агрегат по позициям соответствующего заказа.
o_orderdate		Генерируется в допустимом диапазоне дат TPC-H.
o_orderpriority		Выбирается из словаря приоритетов заказов.
o_clerk		Формируется по шаблону Clerk#%09d.
o_shippriority		Имеет фиксированное значение 0.
o_comment		Выбирается из пула текста TextPool.

3.2.3.8. Таблица lineitem

Атрибут	Ключ	Правило формирования
l_orderkey	FK	Согласован с ключом соответствующего заказа.
l_partkey	FK	Выбирается из диапазона ключей деталей.
l_suppkey	FK	Вычисляется по паре «ключ детали, номер поставщика».
l_linenumber		Задаёт порядковый номер позиции внутри заказа.
l_quantity		Генерируется из ограниченного числового диапазона.
l_extendedprice		Вычисляется по цене детали и количеству.
l_discount		Генерируется как процент скидки из ограниченного диапазона.
l_tax		Генерируется как процент налога из ограниченного диапазона.
l_returnflag		Определяется по отношению даты получения к текущей календарной отметке TPC-H.
l_linestatus		Определяется по отношению даты отгрузки к текущей календарной отметке TPC-H.
l_shipdate		Вычисляется как смещение относительно даты заказа.
l_commitdate		Вычисляется как смещение относительно даты заказа.
l_receiptdate		Вычисляется как смещение относительно даты отгрузки.
l_shipinstruct		Выбирается из словаря инструкций по отгрузке.
l_shipmode		Выбирается из словаря режимов доставки.
l_comment		Выбирается из пула текста TextPool.

3.2.4. Сериализация результатов

После формирования батчей данные передаются в драйвер выбранного формата хранения. Слой сериализации отделен от слоя генерации, поэтому одна и та же схема формирования таблиц может использоваться для нескольких форматов вывода.

Изм.	Лист	№ докум.	Подп.	Дата
RU.17701729.11.03-01 81 01-1				
Инв. № подл.	Подп. и дата	Взам. инв. №	Инв. № дубл.	Подп. и дата

3.2.4.1. Форматы Parquet и ORC.

Форматы Parquet [5] и ORC [6] являются основными колоночными форматами, поддерживаемыми программой. Для них используются две стратегии записи.

При стратегии parallel-files каждая логическая партиция генерируется отдельным рабочим потоком и записывается в собственный файл. Таким образом, для одной таблицы формируется каталог, содержащий набор файлов партиций. Линейный порядок результата при этом задается номерами партиций: каждая партиция соответствует своему непрерывному диапазону строк, а номер партиции фиксируется в имени файла, что позволяет однозначно восстановить общий порядок таблицы при последующем чтении.

При стратегии single-file-ordered генерация партиций также может выполняться параллельно, однако их батчи передаются из рабочих потоков через ограниченную очередь MPSC² одному потоку записи. На стороне потребителя батчи временно буферизуются по номеру партиции и выгружаются в файл только тогда, когда для записи готова очередная ожидаемая партиция. За счет этого порядок данных в итоговом файле эквивалентен последовательной обработке партиций с номерами от 1 до N, несмотря на параллельную генерацию.




Рис. 2 - Схема ручного упорядочения партиций для форматов Parquet и ORC

3.2.4.2. Форматы Lance и Vortex.

Для форматов Lance [8] и Vortex [9] используется другой подход. Схема таблицы, батчи и границы входных партиций передаются в форматно-зависимый мост через интерфейс Arrow C ABI, после чего дальнейшая организация записи делегируется рантайму библиотеки соответствующего формата. В отличие от Parquet и ORC, ручное упорядочение через очередь и буфер по номеру партиции в данном случае не реализуется на стороне программы.

3.3. Организация входных и выходных данных

Входные данные программы представлены параметрами командной строки. К числу основных входных параметров относятся значение scale factor³, перечень формируемых таблиц, формат хранения результата, путь или URI вывода, размер колоночного батча, стратегия записи и форматно-зависимые параметры сериализации.

Предварительно подготовленные табличные входные данные для работы программы не требуются. Все словари, распределения, шаблоны текстов и правила вычисления атрибутов входят в состав программы и используются непосредственно в процессе генерации.

Выходные данные программы представляют собой сформированные таблицы набора TPC-H в поддерживаемом формате хранения. Результат может быть организован либо как набор

²MPSC (multi-producer, single-consumer) - очередь с несколькими источниками и одним потребителем.
³Scale factor - размер формируемого набора данных в гигабайтах [1].

Table with 5 columns: Изм., Лист, № докум., Подп., Дата. Row 1: RU.17701729.11.03-01 81 01-1. Row 2: Инв. № подл., Подп. и дата, Взам. инв. №, Инв. № дубл., Подп. и дата.

файлов-партиций, либо как единый файл таблицы, формируемый из нескольких логических партиций в заранее определенном порядке. Размещение результатов допускается как на локальных носителях данных, так и в S3-совместимых объектных хранилищах.

Внутри программы перед сериализацией данные организуются в виде колоночных батчей, соответствующих схеме выбранной таблицы. Такой способ организации входных и выходных данных уменьшает объем промежуточных преобразований и позволяет непосредственно передавать сформированные батчи в драйверы записи. Выбранная форма представления согласуется с моделью обмена данных Apache Arrow [3].

3.4. Состав технических и программных средств

Подробное описание состава технических и программных средств, а также условий эксплуатации приведено в документе «Руководство оператора», раздел 2 «Условия выполнения программы».

Изм.	Лист	№ докум.	Подп.	Дата
RU.17701729.11.03-01 81 01-1				
Инв. № подл.	Подп. и дата	Взам. инв. №	Инв. № дубл.	Подп. и дата

4. Ожидаемые технико-экономические показатели

4.1. Сокращение трудоемкости подготовки данных

Выбранное техническое решение позволяет исключить промежуточный этап формирования табличных файлов в формате `tbl/csv` [4] с последующей конвертацией в целевой формат хранения. За счет прямой генерации данных в поддерживаемые колоночные форматы `Parquet` [5], `ORC` [6], `Lance` [8] и `Vortex` [9] сокращается количество операций, выполняемых при подготовке наборов данных к нагрузочным испытаниям и исследовательским экспериментам. Детерминированный характер генерации, предусмотренный спецификацией TPC-H [1], дополнительно упрощает повторное проведение экспериментов при одинаковых параметрах запуска.


4.2. Снижение инфраструктурных издержек

Прямая запись результата в локальную файловую систему и в S3-совместимые хранилища позволяет отказаться от отдельного конвейера выгрузки, последующей конвертации и доставки данных в среду выполнения аналитических запросов. Отсутствие обязательной материализации промежуточных форматов уменьшает потребность во временном дисковом пространстве и снижает накладные расходы на подготовку испытательной и исследовательской инфраструктуры.

4.3. Расширение вариантов интеграции

Отделение модуля генерации от слоя сериализации позволяет использовать программу как встраиваемый источник табличных данных. В этом режиме таблицы TPC-H формируются непосредственно в оперативной памяти и передаются потребителю без промежуточной записи на диск. Исходная реализация генератора представлена в репозитории `Schengen` [10].

Такой способ интеграции реализован для СУБД DuckDB в отдельном расширении [11]. Расширение регистрирует представления таблиц TPC-H, а обращение к ним приводит к вызову табличной функции `SCHENGEN_SCAN`, получающей данные напрямую из генератора в виде батчей `Apache Arrow` [3].




Изм.	Лист	№ докум.	Подп.	Дата
RU.17701729.11.03-01 81 01-1				
Инв. № подл.	Подп. и дата	Взам. инв. №	Инв. № дубл.	Подп. и дата


Рис. 3 - Схема интеграции генератора с DuckDB

В листинге 5 приведен пример вывода EXPLAIN DuckDB для запроса TPC-H Q1 [1]. Наличие оператора SCHENGEN_SCAN в нижней части плана показывает, что данные поступают из генератора, а не считываются из файла.

```
D EXPLAIN SELECT
  l_returnflag,
  l_linestatus,
  SUM(l_quantity) AS sum_qty,
  SUM(l_extendedprice) AS sum_base_price,
  SUM(l_extendedprice * (1 - l_discount)) AS sum_disc_price,
  SUM(l_extendedprice * (1 - l_discount) * (1 + l_tax)) AS sum_charge,
  AVG(l_quantity) AS avg_qty,
  AVG(l_extendedprice) AS avg_price,
  AVG(l_discount) AS avg_disc,
  COUNT(*) AS count_order
FROM lineitem
WHERE l_shipdate <= DATE '1998-09-02'
GROUP BY l_returnflag, l_linestatus
ORDER BY l_returnflag, l_linestatus;
```



Изм.	Лист	№ докум.	Подп.	Дата
RU.17701729.11.03-01 81 01-1				
Инв. № подл.	Подп. и дата	Взам. инв. №	Инв. № дубл.	Подп. и дата



Листинг 5 - Вывод DuckDB EXPLAIN для запроса TPC-H Q1

Изм.	Лист	№ докум.	Подп.	Дата
RU.17701729.11.03-01 81 01-1				
Инв. № подл.	Подп. и дата	Взам. инв. №	Инв. № дубл.	Подп. и дата

4.4. Ожидаемые оперативные показатели

К ожидаемым оперативным показателям относятся воспроизводимость набора данных при одинаковых параметрах запуска, возможность параллельной генерации таблиц и партиций, поддержка генерации на больших значениях масштаба, а также прямая запись результата в современные колоночные форматы хранения и удаленные S3-совместимые хранилища. Совокупность указанных свойств обеспечивает пригодность программы для нагрузочных испытаний, сравнительного анализа аналитических СУБД [2] и встраивания в исследовательские конвейеры обработки данных.

Изм.	Лист	№ докум.	Подп.	Дата
RU.17701729.11.03-01 81 01-1				
Инв. № подл.	Подп. и дата	Взам. инв. №	Инв. № дубл.	Подп. и дата

5. Источники, использованные при разработке

- [1] Transaction Processing Performance Council (TPC). TPC Benchmark H Standard Specification, Version 2.17.1. URL: https://www.tpc.org/tpc_documents_current_versions/pdf/tpc-h_v2.17.1.pdf.
- [2] DeWitt D. J., Gray J. Parallel Database Systems: The Future of High Performance Database Systems. URL: <https://pesc.coppe.ufrj.br/~ines/courses/TEPP/pcomp-25-13.26-99.pdf>.
- [3] Apache Arrow: A Cross-Language Development Platform for In-Memory Columnar Data. URL: <https://arrow.apache.org/>.
- [4] TBL Format Specification. URL: <https://en.wikipedia.org/wiki/Troff>.
- [5] Apache Parquet Format Specification. URL: https://en.wikipedia.org/wiki/Apache_Parquet.
- [6] Apache ORC Format Specification. URL: https://en.wikipedia.org/wiki/Apache_ORC.
- [7] Apache Iceberg Format Specification. URL: https://en.wikipedia.org/wiki/Apache_Iceberg.
- [8] Apache Lance Format Specification. URL: <https://github.com/lancedb/lance>.
- [9] Apache Vortex Format Specification. URL: <https://github.com/spiraldB/vortex>.
- [10] Schengen: генератор данных для аналитического бенчмарка TPC-H. URL: <https://github.com/m7kss1/schengen>.
- [11] Schengen-DuckDB: расширение DuckDB для прямой генерации данных TPC-H. URL: <https://github.com/m7kss1/schengen-duckdb>.

Изм.	Лист	№ докум.	Подп.	Дата
RU.17701729.11.03-01 81 01-1				
Инв. № подл.	Подп. и дата	Взам. инв. №	Инв. № дубл.	Подп. и дата

Лист регистрации изменений

[illegible]