

ПРАВИТЕЛЬСТВО РОССИЙСКОЙ ФЕДЕРАЦИИ
НАЦИОНАЛЬНЫЙ ИССЛЕДОВАТЕЛЬСКИЙ УНИВЕРСИТЕТ
«ВЫСШАЯ ШКОЛА ЭКОНОМИКИ»

Факультет компьютерных наук
Департамент программной инженерии

СОГЛАСОВАНО

УТВЕРЖДАЮ

Профессор департамента программной инженерии ФКН НИУ ВШЭ

Академический руководитель образовательной программы «Программная инженерия»

« ____ » _____ 2026 г.

« ____ » _____ 2026 г.

ГЕНЕРАТОР ДАННЫХ ДЛЯ АНАЛИТИЧЕСКОГО
БЕНЧМАРКА СУБД ТРС-Н

Руководство оператора

Лист УТВЕРЖДЕНИЯ

RU.17701729.11.03-01 34 01-1-ЛУ

Подп. и дата	
Инв. № дубл.	
Взам. инв. №	
Подп. и дата	
Инв. № подл	

Исполнитель: Студент БПИ225

« ____ » _____ 2026 г.

УТВЕРЖДЁН
RU.17701729.11.03-01 34 01-1-ЛУ

ГЕНЕРАТОР ДАННЫХ ДЛЯ АНАЛИТИЧЕСКОГО
БЕНЧМАРКА СУБД ТРС-Н

Руководство оператора

RU.17701729.11.03-01 34 01-1

Листов 10

Инв. № подл	Подп. и дата	Взам. инв. №	Инв. № дубл.	Подп. и дата

Аннотация

Настоящий документ содержит сведения, необходимые для подготовки, загрузки, запуска, выполнения и завершения программы генерации данных для аналитического бенчмарка СУБД ТРС-Н.

В документе приведены назначение программы, условия ее выполнения, порядок использования командного интерфейса, а также сведения о сообщениях, выдаваемых в ходе работы.

Содержание

Аннотация	2
1 Назначение программы	3
1.1 Назначение программы	3
1.2 Функции программы	3
1.3 Сведения по эксплуатации программы	3
2 Условия выполнения программы	4
2.1 Минимальный состав технических средств	4
2.2 Максимальный состав технических средств	4
2.3 Программные средства	4
2.4 Дополнительные условия выполнения программы	4
3 Выполнение программы	5
3.1 Подготовка к работе	5
3.2 Загрузка программы	5
3.3 Запуск программы	5
3.4 Команды оператора	6
3.5 Управление выполнением программы	7
3.6 Завершение работы программы	7
3.7 Примеры выполнения	7
4 Сообщения оператору	8
4.1 Сообщения, выдаваемые в ходе выполнения программы	8
4.2 Действия оператора	8
4.3 Таблица сообщений	8

Изм.	Лист	№ докум.	Подп.	Дата
RU.17701729.11.03-01 34 01-1				
Инв. № подл.	Подп. и дата	Взам. инв. №	Инв. № дубл.	Подп. и дата

1. Назначение программы

1.1. Назначение программы

Программа предназначена для генерации синтетических аналитических данных набора ТРС-Н и сохранения результатов в колоночных форматах хранения данных. Программа используется как утилита командной строки и обеспечивает подготовку таблиц фиксированного набора с заданным масштабом генерации.

1.2. Функции программы

Программа обеспечивает выполнение следующих основных функций:

- 1) генерация таблиц набора ТРС-Н;
- 2) выбор масштаба генерации посредством параметра scale factor;
- 3) выбор одной или нескольких таблиц для генерации;
- 4) вывод результата в поддерживаемый формат хранения данных;
- 5) управление параметрами батчирования и стратегии записи;
- 6) вывод списка доступных таблиц и форматов;
- 7) вывод диагностических сообщений и сообщений о ходе выполнения.

1.3. Сведения по эксплуатации программы

Эксплуатация программы выполняется оператором из командной строки. Оператор задает параметры запуска, определяющие формат результата, путь вывода, перечень таблиц, а также дополнительные параметры записи и отображения хода выполнения.

Результатом работы программы являются сформированные файлы данных в указанном каталоге или по указанному URI. При ошибках запуска или недопустимых параметрах программа завершает работу с ненулевым кодом возврата и выводит диагностическое сообщение.

Изм.	Лист	№ докум.	Подп.	Дата
RU.17701729.11.03-01 34 01-1				
Инв. № подл.	Подп. и дата	Взам. инв. №	Инв. № дубл.	Подп. и дата

2. Условия выполнения программы

2.1. Минимальный состав технических средств

Для выполнения программы требуется вычислительное устройство, обеспечивающее запуск 64-разрядных приложений и запись выходных файлов на локальную файловую систему либо в доступное оператору хранилище.

Минимально необходимыми техническими средствами являются:

- 1) 64-разрядный процессор;
- 2) оперативная память, достаточная для формирования выходных батчей;
- 3) дисковое пространство, достаточное для размещения результатов генерации.

2.2. Максимальный состав технических средств

При эксплуатации программы на больших значениях масштаба генерации целесообразно использовать многоядерный процессор, увеличенный объем оперативной памяти и дисковую подсистему с высокой пропускной способностью. Это позволяет эффективно использовать многопоточную обработку партиций и сократить время записи выходных данных.

2.3. Программные средства

Для выполнения программы должны быть доступны:

- 1) 64-разрядная операционная система семейства Linux;
- 2) собранный исполняемый файл программы `schengen_main`;
- 3) программные библиотеки, необходимые для форматов, включенных в текущую сборку программы;
- 4) права на чтение входного каталога запуска и запись в каталог или URI вывода.

2.4. Дополнительные условия выполнения программы

При использовании удаленных URI оператор должен обеспечить сетевую доступность соответствующей файловой системы или объектного хранилища.

При выборе форматов вывода оператор должен учитывать, что набор поддерживаемых форматов определяется конфигурацией конкретной сборки программы.

Изм.	Лист	№ докум.	Подп.	Дата
RU.17701729.11.03-01 34 01-1				
Инв. № подл.	Подп. и дата	Взам. инв. №	Инв. № дубл.	Подп. и дата

3. Выполнение программы

3.1. Подготовка к работе

Перед запуском программы оператор должен:

- 1) убедиться в наличии исполняемого файла программы;
- 2) определить каталог или URI вывода результатов;
- 3) выбрать формат хранения выходных данных;
- 4) определить масштаб генерации и перечень таблиц;
- 5) проверить наличие прав на запись в целевой каталог или хранилище.

3.2. Загрузка программы

Программа не требует отдельной процедуры загрузки в память оператором и запускается как обычное консольное приложение из командной строки.

Общий вид вызова программы:

```
schengen_main [параметры]
```

3.3. Запуск программы

Для получения справки оператор должен использовать команду:

```
schengen_main --help
```

Для вывода списка доступных таблиц используется команда:

```
schengen_main --list-tables
```

Для вывода списка доступных форматов используется команда:

```
schengen_main --list-formats
```

Пример типового запуска программы:

```
schengen_main \  
--scale-factor 1 \  
--output-format parquet \  
--output-path ./out \  
--table customer orders lineitem
```

Изм.	Лист	№ докум.	Подп.	Дата
RU.17701729.11.03-01 34 01-1				
Инв. № подл.	Подп. и дата	Взам. инв. №	Инв. № дубл.	Подп. и дата

3.4. Команды оператора

Основными параметрами командной строки являются:

- 1) `-help` – вывод справки;
- 2) `-list-tables` – вывод списка доступных таблиц;
- 3) `-list-formats` – вывод списка доступных форматов;
- 4) `-scale-factor` – задание масштаба генерации;
- 5) `-output-format` – задание формата выходных данных;
- 6) `-output-path` – задание каталога или URI вывода;
- 7) `-table` – указание одной или нескольких таблиц для генерации;
- 8) `-batch-rows` – задание числа строк в батче;
- 9) `-write-strategy` – выбор стратегии записи;
- 10) `-write-workers` – задание числа рабочих потоков обработки;
- 11) `-write-queue-capacity` – задание емкости очереди записи;
- 12) `-verbosity` – выбор режима вывода хода выполнения.

Для формата `parquet` могут использоваться дополнительные параметры:

- 1) `-parquet-use-threads`;
- 2) `-parquet-row-group-bytes`;
- 3) `-parquet-max-row-group-rows`;
- 4) `-parquet-output-buffer-bytes`;
- 5) `-parquet-compression`.

Для формата `orc` могут использоваться дополнительные параметры:

- 1) `-orc-max-partition-rows`;
- 2) `-orc-stripe-bytes`;
- 3) `-orc-max-stripe-rows`;
- 4) `-orc-output-buffer-bytes`;
- 5) `-orc-compression`.

Изм.	Лист	№ докум.	Подп.	Дата
RU.17701729.11.03-01 34 01-1				
Инв. № подл.	Подп. и дата	Взам. инв. №	Инв. № дубл.	Подп. и дата

3.5. Управление выполнением программы

Если параметр `-verbosity verbose` задан, программа выводит сведения о ходе выполнения по таблицам. Если параметр `-verbosity quiet` не изменен, программа работает в минимальном режиме вывода и сообщает оператору преимущественно об ошибках.

Стратегия записи задается параметром `-write-strategy`. Допустимыми значениями являются:

- 1) `auto`;
- 2) `parallel-files`;
- 3) `single-file-ordered`.

Число потоков обработки задается параметром `-write-workers`. Значение 0 означает автоматический выбор.

3.6. Завершение работы программы

После завершения генерации программа закрывает используемые потоки обработки, завершает запись выходных данных и возвращает код завершения в операционную систему.

При успешном завершении программа возвращает код 0. При ошибке параметров запуска, неподдерживаемом формате, недопустимой стратегии записи либо сбое выполнения программа возвращает ненулевой код завершения.

3.7. Примеры выполнения

Пример генерации всех таблиц в формат `parquet`:

```
schengen_main --scale-factor 1 --output-format parquet --output-path ./out
```

Пример генерации выбранных таблиц в формате `orc`:

```
schengen_main \
  --scale-factor 1 \
  --output-format orc \
  --output-path ./out_orc \
  --table customer orders lineitem
```

Пример запуска с подробным выводом хода выполнения:

```
schengen_main \
  --scale-factor 1 \
  --output-format parquet \
  --output-path ./out \
  --verbosity verbose
```

Изм.	Лист	№ докум.	Подп.	Дата
RU.17701729.11.03-01 34 01-1				
Инв. № подл.	Подп. и дата	Взам. инв. №	Инв. № дубл.	Подп. и дата

4. Сообщения оператору

4.1. Сообщения, выдаваемые в ходе выполнения программы

В ходе выполнения программа может выдавать оператору справочные, диагностические и ошибочные сообщения. Сообщения выводятся в стандартный поток вывода или в стандартный поток ошибок в зависимости от характера операции.

К справочным сообщениям относятся вывод списка таблиц, списка форматов и полной справки по параметрам запуска. К сообщениям об ошибках относятся уведомления о неверных аргументах командной строки, недопустимых значениях параметров, неизвестных таблицах и неподдерживаемых форматах или режимах выполнения.

4.2. Действия оператора

При получении сообщения об ошибке оператор должен:

- 1) проверить корректность имени таблицы, формата и переданных параметров;
- 2) проверить допустимость числовых значений параметров;
- 3) убедиться, что выбранный формат поддерживается текущей сборкой;
- 4) повторить запуск программы после исправления параметров;
- 5) при необходимости использовать `-help`, `-list-tables` и `-list-formats` для уточнения допустимых значений.

4.3. Таблица сообщений

Сообщение	Описание	Действия оператора
<code>Invalid arguments: ...</code>	Ошибка разбора аргументов командной строки.	Проверить синтаксис команды и повторить запуск.
<code>Scale factor must be > 0</code>	Задано недопустимое значение масштаба генерации.	Указать положительное значение параметра <code>-scale-factor</code> .
<code>Batch rows must be > 0</code>	Задано недопустимое число строк в батче.	Указать положительное значение параметра <code>-batch-rows</code> .
<code>Unknown table: ...</code>	Указано имя таблицы, отсутствующее в поддерживаемом наборе.	Проверить имя таблицы или предварительно выполнить <code>'-list-tables'</code> .
<code>Invalid writer options: ...</code>	Переданы недопустимые параметры выбранного формата записи.	Проверить параметры формата и повторить запуск.
<code>Invalid write scheduler options: ...</code>	Переданы недопустимые параметры планировщика записи.	Проверить значения <code>-write-strategy</code> , <code>-write-workers</code> и <code>-write-queue-capacity</code> .

Изм.	Лист	№ докум.	Подп.	Дата
RU.17701729.11.03-01 34 01-1				
Инв. № подл.	Подп. и дата	Взам. инв. №	Инв. № дубл.	Подп. и дата

Сообщение	Описание	Действия оператора
Unsupported output format: ...	Указан формат, не поддерживаемый текущей сборкой программы.	Проверить вывод <code>-list-formats</code> и выбрать допустимый формат.
Unsupported write-strategy: ...	Указана неподдерживаемая стратегия записи.	Использовать одно из допустимых значений: <code>auto</code> , <code>parallel-files</code> , <code>single-file-ordered</code> .
Unsupported verbosity: ...	Указан неподдерживаемый режим вывода.	Использовать <code>quiet</code> или <code>verbose</code> .
Table task failed: ...	Ошибка выполнения одной из задач генерации таблицы.	Проверить параметры запуска, доступность ресурсов и повторить запуск.

Изм.	Лист	№ докум.	Подп.	Дата
RU.17701729.11.03-01 34 01-1				
Инв. № подл.	Подп. и дата	Взам. инв. №	Инв. № дубл.	Подп. и дата

Лист регистрации изменений

[illegible]