

ПРАВИТЕЛЬСТВО РОССИЙСКОЙ ФЕДЕРАЦИИ
НАЦИОНАЛЬНЫЙ ИССЛЕДОВАТЕЛЬСКИЙ УНИВЕРСИТЕТ
«ВЫСШАЯ ШКОЛА ЭКОНОМИКИ»

Факультет компьютерных наук
Департамент программной инженерии

СОГЛАСОВАНО

УТВЕРЖДАЮ

Профессор департамента программной инженерии ФКН НИУ ВШЭ

Академический руководитель образовательной программы «Программная инженерия»

« ____ » _____ 2026 г.

« ____ » _____ 2026 г.

ГЕНЕРАТОР ДАННЫХ ДЛЯ АНАЛИТИЧЕСКОГО
БЕНЧМАРКА СУБД ТРС-Н

Техническое задание

Лист УТВЕРЖДЕНИЯ

RU.17701729.04.03-01 ТЗ 01-1-ЛУ

Подп. и дата	
Инв. № дубл.	
Взам. инв. №	
Подп. и дата	
Инв. № подл	

Исполнитель: Студент БПИ225

« ____ » _____ 2026 г.

УТВЕРЖДЁН
RU.17701729.04.03-01 ТЗ 01-1-ЛУ

ГЕНЕРАТОР ДАННЫХ ДЛЯ АНАЛИТИЧЕСКОГО
БЕНЧМАРКА СУБД ТРС-Н

Техническое задание

RU.17701729.04.03-01 ТЗ 01-1

Листов 12

Инв. № подл	Подп. и дата	Взам. инв. №	Инв. № дубл.	Подп. и дата

Содержание

1	Введение	3
1.1	Наименование программы	3
1.2	Краткая характеристика области применения	3
1.3	Основание для разработки	3
2	Назначение разработки	4
2.1	Функциональное назначение	4
2.2	Эксплуатационное назначение	4
3	Требования к программе	5
3.1	Требования к функциональным характеристикам	5
3.2	Требования к интерфейсу	6
3.3	Требования к формату входных и выходных данных	6
3.4	Условия эксплуатации	7
3.5	Требования к составу и параметрам технических средств	7
3.6	Требования к информационной и программной совместимости	7
3.7	Требования к составу сетевых средств	7
3.8	Требования к программной документации	8
3.9	Требования к маркировке и упаковке	8
4	Стадии и этапы разработки	9
5	Порядок контроля и приемки	10
6	Технико-экономические показатели	11

Изм.	Лист	№ докум.	Подп.	Дата
RU.17701729.04.03-01 ТЗ 01-1				
Инв. № подл.	Подп. и дата	Взам. инв. №	Инв. № дубл.	Подп. и дата

1. Введение

1.1. Наименование программы

1.1.1. Наименование программы на русском языке

Генератор данных для аналитического бенчмарка СУБД ТРС-Н.

1.1.2. Наименование программы на английском языке

Data Generator for the TPC-H Analytical DBMS Benchmark.

1.2. Краткая характеристика области применения

На момент разработки существует потребность в генераторах синтетических аналитических данных, пригодных не только для получения эталонных таблиц набора данных ТРС-Н, но и для непосредственной записи результатов в современные колоночные форматы хранения.

Во многих практических сценариях разработки и исследования OLAP-систем, lakehouse-платформ и подсистем хранения данных недостаточно иметь только строковое представление результата, так как требуется возможность управлять масштабом генерации, батчированием, физическим форматом хранения и стратегией записи партиций.

Данная программа нацелена в первую очередь упростить процесс подготовки воспроизводимых аналитических наборов данных для тестирования, профилирования и верификации систем обработки данных, предоставляя пользователю единый инструмент генерации, колоночного представления и сериализации результата.

Также преследуется цель предоставления пользователю возможности работать с несколькими форматами хранения и сценариями записи, не изменяя внутреннюю реализацию генерационного контура.

1.3. Основание для разработки

Основанием для разработки является тема выпускной квалификационной работы, посвященной проектированию и реализации генератора таблиц набора данных ТРС-Н с поддержкой колоночного представления данных, нескольких форматов хранения и параллельных стратегий записи.

Изм.	Лист	№ докум.	Подп.	Дата
RU.17701729.04.03-01 ТЗ 01-1				
Инв. № подл.	Подп. и дата	Взам. инв. №	Инв. № дубл.	Подп. и дата

2. Назначение разработки

2.1. Функциональное назначение

Функциональным назначением программы является обеспечение процесса детерминированной генерации таблиц набора данных ТРС-Н с возможностью формирования результатов в виде колоночных батчей и сохранения их в различных форматах хранения. Генерация должна выполняться с учетом scale factor, зависимостей между таблицами, возможности независимой обработки партиций и поддержки нескольких стратегий записи, что позволяет использовать программу как для получения файлового результата, так и для исследования характеристик слоя хранения.

2.2. Эксплуатационное назначение

Данная программа может быть использована разработчиком, исследователем или инженером по тестированию для подготовки синтетических аналитических данных, используемых при проверке OLAP-систем, подсистем хранения, форматов сериализации и сценариев многопоточной записи. Программа ориентирована на построение воспроизводимых наборов данных различного масштаба, пригодных для локального анализа, нагрузочного тестирования и исследовательских экспериментов.

Также, наличие единого генерационного контура, отделенного от слоя хранения, позволяет использовать программу не только как утилиту формирования файлов, но и как основу для дальнейшей интеграции с аналитическими системами, принимающими колоночные батчи непосредственно в память.

Изм.	Лист	№ докум.	Подп.	Дата
RU.17701729.04.03-01 ТЗ 01-1				
Инв. № подл.	Подп. и дата	Взам. инв. №	Инв. № дубл.	Подп. и дата

3. Требования к программе

3.1. Требования к функциональным характеристикам

Программа должна реализовывать генерацию таблиц набора данных ТРС-Н с учетом детерминированных правил синтеза значений, зависимостей между таблицами и возможности независимой обработки партиций. При необходимости, если этого будет требовать реализация сценария хранения, программа должна обеспечивать формирование промежуточного колоночного представления данных в памяти и запись результата в поддерживаемые форматы хранения с различными параметрами сериализации.

Программа также должна реализовывать возможность выбора стратегии записи, позволяющую пользователю либо максимизировать пропускную способность за счет записи партиций в отдельные файлы, либо формировать один итоговый файл таблицы при сохранении параллельной генерации, что позволяет использовать программу в различных сценариях тестирования и исследования.

Разрабатываемая программа должна:

- 1) генерировать и сохранять таблицы набора данных ТРС-Н;
- 2) поддерживать генерацию следующих таблиц:
 - region;
 - nation;
 - supplier;
 - part;
 - partsupp;
 - customer;
 - orders;
 - lineitem.
- 3) изменять масштаб генерируемого набора данных посредством параметра scale factor;
- 4) формировать данные батчами фиксированного размера в колоночном представлении;
- 5) позволять пользователю выбирать набор генерируемых таблиц;
- 6) переводить сгенерированные данные в различные форматы хранения:
 - parquet;
 - orc;
 - lance;
 - vortex.
- 7) поддерживать различные стратегии записи:
 - parallel-files;
 - single-file-ordered.

Изм.	Лист	№ докум.	Подп.	Дата
RU.17701729.04.03-01 ТЗ 01-1				
Инв. № подл.	Подп. и дата	Взам. инв. №	Инв. № дубл.	Подп. и дата

- 8) позволять пользователю управлять параметрами генерации и записи:
 - размером батча;
 - количеством рабочих потоков;
 - емкостью очереди записи;
 - параметрами компрессии и партиционирования.
- 9) обеспечивать детерминированность результата при изменении конфигурации партиционирования и числа потоков;
- 10) выводить список доступных таблиц и форматов;
- 11) выполнять проверку корректности параметров запуска и выдавать диагностические сообщения пользователю.

3.2. Требования к интерфейсу

Программа должна иметь командный интерфейс, позволяющий пользователю работать с программой с минимальной предварительной подготовкой.

Интерфейс должен позволять:

- 1) получать справочную информацию о параметрах запуска;
- 2) выводить список поддерживаемых таблиц;
- 3) выводить список поддерживаемых форматов хранения;
- 4) задавать scale factor, формат хранения, путь вывода и набор генерируемых таблиц;
- 5) задавать размер батча, стратегию записи, число потоков и дополнительные параметры форматов;
- 6) получать сообщения о ходе выполнения и об ошибках.

3.3. Требования к формату входных и выходных данных

3.3.1. Входные данные

Одна из основных задач программы - предоставить пользователю возможность управлять процессом генерации аналитических таблиц, не изменяя исходный код программы и не подготавливая входные файлы вручную. Пользователь должен иметь возможность задавать параметры генерации через командный интерфейс, определяя масштаб набора данных, набор таблиц, формат хранения, путь вывода, стратегию записи и параметры батчирования.

Исходя из этого, входными данными для программы должны являться параметры командной строки, определяющие сценарий генерации. В состав входных данных должны входить значение scale factor, список генерируемых таблиц, формат хранения, путь или URI вывода, размер батча, стратегия записи, число рабочих потоков, емкость очереди записи, а также форматно-зависимые параметры, например параметры компрессии и логического партиционирования.

Программа не должна требовать от пользователя наличия предварительно подготовленных табличных данных. Правила генерации, словари, распределения и зависимости набора данных ТРС-Н должны входить в состав программы и использоваться непосредственно в процессе генерации.

Изм.	Лист	№ докум.	Подп.	Дата
RU.17701729.04.03-01 ТЗ 01-1				
Инв. № подл.	Подп. и дата	Взам. инв. №	Инв. № дубл.	Подп. и дата

3.3.2. Выходные данные

Программа должна позволять пользователю сохранять сгенерированные таблицы в различных колоночных форматах с различными параметрами записи.

В зависимости от выбранной стратегии записи результатом работы программы должны являться либо отдельные файлы-партиции, либо один итоговый файл таблицы, формируемый из нескольких параллельно сгенерированных партиций. При необходимости программа должна иметь возможность записи результатов в виде набора файлов по URI, совместимому с поддерживаемой файловой системой.

3.4. Условия эксплуатации

3.4.1. Климатические условия

Климатические условия совпадают с климатическими условиями эксплуатации вычислительного устройства, на котором запускается программа.

3.4.2. Требования к пользователю

Пользователь должен иметь базовое представление о командном интерфейсе операционной системы, файловой системе и принципах работы с параметрами запуска программ. Также пользователь должен обладать базовыми знаниями о структуре набора данных ТРС-Н, колоночных форматах хранения данных и назначении синтетических аналитических данных.

3.5. Требования к составу и параметрам технических средств

Для корректной работы программы необходимо вычислительное устройство с 64-разрядным процессором и достаточным объемом оперативной памяти для формирования колоночных батчей и параллельной записи данных. Для типовых сценариев генерации рекомендуется наличие многоядерного процессора, не менее 8 ГБ оперативной памяти и дисковой подсистемы, допускающей запись файлов требуемого размера.

3.6. Требования к информационной и программной совместимости

На устройстве должна быть установлена 64-разрядная операционная система семейства Linux, обеспечивающая совместимую сборку и запуск программы. Для сборки и корректной работы программы должны быть доступны система сборки CMake, компилятор с поддержкой стандарта C++17, библиотека Apache Arrow, а также библиотеки, необходимые для используемых форматов хранения и подсистемы параллельного выполнения. Выходные данные программы должны быть совместимы с программными средствами, поддерживающими чтение соответствующих форматов хранения.

3.7. Требования к составу сетевых средств

Для базового сценария генерации с записью результатов на локальную файловую систему наличие доступа к сети не требуется. При использовании удаленных URI и объектных хранилищ у вычислительного устройства должен быть доступ к соответствующей сети передачи данных.

Изм.	Лист	№ докум.	Подп.	Дата
RU.17701729.04.03-01 ТЗ 01-1				
Инв. № подл.	Подп. и дата	Взам. инв. №	Инв. № дубл.	Подп. и дата

3.8. Требования к программной документации

В состав программной документации должны входить следующие компоненты:

- 1) Техническое задание
- 2) Программа и методика испытаний
- 3) Отчет
- 4) Руководство оператора
- 5) Текст программы

3.9. Требования к маркировке и упаковке

Программа должна поставляться в виде репозитория исходных текстов или архива с исходными файлами, файлами сборки и программной документацией. При необходимости допускается поставка собранного исполняемого файла программы вместе с инструкцией по запуску.

Изм.	Лист	№ докум.	Подп.	Дата
RU.17701729.04.03-01 ТЗ 01-1				
Инв. № подл.	Подп. и дата	Взам. инв. №	Инв. № дубл.	Подп. и дата

4. Стадии и этапы разработки

1) техническое задание:

- этапы разработки:
 - а) обоснование необходимости разработки генератора аналитических данных;
 - б) постановка задачи;
 - в) сбор исходных материалов по спецификации ТРС-Н и форматам хранения данных;
 - г) выбор и обоснование критериев эффективности и качества разрабатываемой программы;
 - д) обоснование необходимости проведения исследований стратегий записи и параллельной генерации;
- разработка и утверждение технического задания:
 - а) определение требований к программе;
 - б) определение стадий, этапов и сроков разработки программы и документации на неё;
 - в) согласование и утверждение технического задания;

2) технический проект:

- разработка технического проекта:
 - а) уточнение структуры входных и выходных данных;
 - б) разработка алгоритмов детерминированной генерации, партиционирования и записи данных;
 - в) определение формы представления входных и выходных данных;
 - г) разработка структуры генерационного фреймворка, слоя хранения и командного интерфейса;
 - д) окончательное определение конфигурации технических средств.
- утверждение технического проекта:
 - а) разработка отчета;
 - б) согласование и утверждение технического проекта.

3) рабочий проект:

- разработка программы:
 - а) программирование и отладка генератора таблиц, форматов хранения и командного интерфейса.
- разработка программной документации:
 - а) разработка программных документов в соответствии с требованиями гост 19.101-77.
- испытания программы:
 - а) разработка, согласование и утверждение порядка и методики испытаний;
 - б) корректировка программы и программной документации по результатам испытаний.

Изм.	Лист	№ докум.	Подп.	Дата
RU.17701729.04.03-01 ТЗ 01-1				
Инв. № подл.	Подп. и дата	Взам. инв. №	Инв. № дубл.	Подп. и дата

5. Порядок контроля и приемки

Контроль и приемка разработки осуществляются в соответствии с документом «Программа и методика испытаний».

В ходе приемки должна проверяться корректность генерации таблиц набора данных ТРС-Н, соответствие числа строк выбранному scale factor, детерминированность результата при различных конфигурациях партиционирования и параллельного выполнения, а также корректность записи данных в поддерживаемые форматы хранения.

Изм.	Лист	№ докум.	Подп.	Дата
RU.17701729.04.03-01 ТЗ 01-1				
Инв. № подл.	Подп. и дата	Взам. инв. №	Инв. № дубл.	Подп. и дата

6. Техничко-экономические показатели

На сегодняшний момент количество аналитических систем, движков хранения и исследовательских стендов, работающих с колоночными форматами данных, растет с каждым днем. Для разработки, тестирования и сравнения таких систем требуется воспроизводимый источник синтетических данных, позволяющий быстро получать таблицы набора ТРС-Н в различных форматах хранения и с различными стратегиями записи. Предполагается, что данная программа позволит сократить затраты времени на подготовку тестовых наборов данных, упростить экспериментирование с форматами хранения и повысить удобство разработки и верификации аналитических систем.

Изм.	Лист	№ докум.	Подп.	Дата
RU.17701729.04.03-01 ТЗ 01-1				
Инв. № подл.	Подп. и дата	Взам. инв. №	Инв. № дубл.	Подп. и дата

Лист регистрации изменений

[illegible]